

EDA_and_Insights

July 2, 2025

1 Restaurant Transactions Analysis

1.1 Project Overview

This project is part of a data analysis challenge aimed at exploring and extracting insights from a dataset of restaurant transactions. The dataset includes detailed information about sales, products, taxation, and customer behavior.

This challenge was designed to be open-ended to showcase analytical and technical skills in Python, data wrangling, visualization, and reporting.

```
[1]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

pd.set_option('display.max_columns', None)
sns.set(style="whitegrid")

%matplotlib inline
```

```
[15]: # Caricamento CSV
df = pd.read_csv("/home/giovanni01/Scrivania/restaurant-data-challenge/
↳restaurant-analitics/data/transactions.csv")

print("Dimensioni del dataset:", df.shape)
df.head(20)
```

Dimensioni del dataset: (664633, 15)

```
[15]:
```

	Date	Transaction ID	Table ID	# guests	\
0	2021-06-01 09:34:59	17085	NO TAVOLO	0	
1	2021-06-01 12:16:00	4405	ASP2	0	
2	2021-06-01 12:16:00	4405	ASP2	0	
3	2021-06-01 12:16:00	4405	ASP2	0	
4	2021-06-01 12:16:00	4405	ASP2	0	
5	2021-06-01 12:16:00	4405	ASP2	0	
6	2021-06-01 12:16:00	4405	ASP2	0	
7	2021-06-01 12:16:00	4405	ASP2	0	

8	2021-06-01 12:16:00	4405	ASP2	0
9	2021-06-01 12:16:00	4406	ARA7	1
10	2021-06-01 12:16:00	4406	ARA7	1
11	2021-06-01 12:16:00	4406	ARA7	1
12	2021-06-01 12:16:00	4406	ARA7	1
13	2021-06-01 12:16:00	4406	ARA7	1
14	2021-06-01 12:16:00	4406	ARA7	1
15	2021-06-01 12:16:00	4406	ARA7	1
16	2021-06-01 12:16:00	4406	ARA7	1
17	2021-06-01 12:27:00	4404	ARA6	1
18	2021-06-01 12:27:00	4404	ARA6	1
19	2021-06-01 12:27:00	4404	ARA6	1

	Category and product ID	Product category	Product ID	Amount	Price \
0	ET00345	ET00345	ET00345	1.5	31.5
1	PIZZE-00071	PIZZE	71	1.0	8.0
2	IMPAST PIZZA-0003	IMPASTPIZZA	3	1.0	0.0
3	BEVERAGE-00111	BEVERAGE	111	1.0	1.0
4	BEVERAGE-00004	BEVERAGE	4	1.0	3.0
5	COPERTO - 00001	COPERTO	1	1.0	2.5
6	PIZZE-00011	PIZZE	11	1.0	9.5
7	IMPAST PIZZA-0003	IMPASTPIZZA	3	1.0	0.0
8	CAFFETTERIA-00001	CAFFETTERIA	1	1.0	2.0
9	PIZZE-00071	PIZZE	71	1.0	8.0
10	IMPAST PIZZA-0003	IMPASTPIZZA	3	1.0	0.0
11	BEVERAGE-00111	BEVERAGE	111	1.0	1.0
12	BEVERAGE-00004	BEVERAGE	4	1.0	3.0
13	COPERTO - 00001	COPERTO	1	1.0	2.5
14	PIZZE-00011	PIZZE	11	1.0	9.5
15	IMPAST PIZZA-0003	IMPASTPIZZA	3	1.0	0.0
16	CAFFETTERIA-00001	CAFFETTERIA	1	1.0	2.0
17	BIRRE-00329	BIRRE	329	1.0	6.0
18	COPERTO - 00001	COPERTO	1	1.0	2.5
19	PIZZE-01161	PIZZE	1161	1.0	14.0

	Taxation type	Tax rate %	Tax	Net minus tax \
0	2	10	3.15	28.35
1	2	10	0.80	7.20
2	2	10	0.00	0.00
3	2	10	0.10	0.90
4	2	10	0.30	2.70
5	2	10	0.25	2.25
6	2	10	0.95	8.55
7	2	10	0.00	0.00
8	2	10	0.20	1.80
9	2	10	0.80	7.20
10	2	10	0.00	0.00

11	2	10	0.10	0.90
12	2	10	0.30	2.70
13	2	10	0.25	2.25
14	2	10	0.95	8.55
15	2	10	0.00	0.00
16	2	10	0.20	1.80
17	2	10	0.60	5.40
18	2	10	0.25	2.25
19	2	10	1.40	12.60

	At the table	Takeaway/Delivery	Lunch/Dinner
0	Asporto/Delivery	Pranzo	
1	Asporto/Delivery	Pranzo	
2	Asporto/Delivery	Pranzo	
3	Asporto/Delivery	Pranzo	
4	Asporto/Delivery	Pranzo	
5	Asporto/Delivery	Pranzo	
6	Asporto/Delivery	Pranzo	
7	Asporto/Delivery	Pranzo	
8	Asporto/Delivery	Pranzo	
9	Coperto	Pranzo	
10	Coperto	Pranzo	
11	Coperto	Pranzo	
12	Coperto	Pranzo	
13	Coperto	Pranzo	
14	Coperto	Pranzo	
15	Coperto	Pranzo	
16	Coperto	Pranzo	
17	Coperto	Pranzo	
18	Coperto	Pranzo	
19	Coperto	Pranzo	

```
[3]: # Conversione data
df['Date'] = pd.to_datetime(df['Date'])

# Rinomina colonne
df.columns = df.columns.str.strip().str.replace(" ", "_")

# Drop duplicati e copia esplicita per evitare warning
print(f"Righe prima: {len(df)}")
df = df.drop_duplicates().copy()
print(f"Righe dopo drop duplicates: {len(df)}")

num_cols = ['Price', 'Tax', 'Tax_rate_%', 'Net_minus_tax', 'Amount', '#_guests']
for col in num_cols:
    df.loc[:, col] = pd.to_numeric(df[col], errors='coerce')
```

```
# Controllo valori nulli
print("Valori nulli:\n", df.isnull().sum())
```

Righe prima: 664633

Righe dopo drop duplicates: 539413


Valori nulli:

Date	0
Transaction_ID	0
Table_ID	0
#_guests	0
Category_and_product_ID	0
Product_category	0
Product_ID	0
Amount	0
Price	0
Taxation_type	0
Tax_rate_%	0
Tax	0
Net_minus_tax	0
At_the_table_Takeaway/Delivery	0
Lunch/Dinner	0

dtype: int64

[4]: #1. *Andamento giornaliero delle vendite*


```
vendite_giornaliere = df.groupby('Date')['Price'].sum()
vendite_giornaliere.plot(figsize=(14,4), title='Vendite giornaliere',
    ↳ylabel='€')
plt.grid(True)
plt.tight_layout()
plt.show()
```



[5]: #2. *Distribuzione Lunch vs Dinner*

```
sns.countplot(data=df, x='Lunch/Dinner')
```

```
plt.title("Distribuzione dei pasti")
plt.show()
```



```
[6]: #3. Scontrino medio per transazione
```

```
scontrino_medio = df.groupby('Transaction_ID')['Price'].sum().mean()
print(" Scontrino medio: €", round(scontrino_medio, 2))
```

Scontrino medio: € 73.56

```
[7]: #4. Numero medio di ospiti per transazione
```

```
ospiti_medi = df.groupby('Transaction_ID')['#_guests'].max().mean()
print(" Ospiti medi per transazione:", round(ospiti_medi, 2))
```

Ospiti medi per transazione: 2.06

```
[8]: #5. Top 10 prodotti più venduti per quantità
```

```
# Etichetta per prodotto
```

```

df['Product_Label'] = df['Product_category'] + " - " + df['Product_ID'].
↳astype(str)

# Calcolo top 10 quantità
top_prodotti = df.groupby('Product_Label')['Amount'].sum().
↳sort_values(ascending=False).head(10).reset_index()

# Grafico
plt.figure(figsize=(10, 6))
sns.barplot(
    data=top_prodotti,
    x='Amount',
    y='Product_Label',
    palette=sns.color_palette("tab10", n_colors=10)
)
plt.title("Top 10 Prodotti più Venduti (per quantità)")
plt.xlabel("Quantità venduta")
plt.ylabel("Prodotto")

for index, row in top_prodotti.iterrows():
    plt.text(row['Amount'] + max(top_prodotti['Amount'])*0.01, index,
            int(row['Amount']), va='center')


plt.tight_layout()
plt.show()

```

/tmp/ipykernel_702341/838677097.py:11: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `y` variable to `hue` and set `legend=False` for the same effect.

```
sns.barplot(
```



```
[9]: # 6. Top 10 Prodotti per Incasso Totale

# Calcolo top 10 incasso
top_valore = df.groupby('Product_Label')['Price'].sum().
    ↪sort_values(ascending=False).head(10).reset_index()

# Grafico
plt.figure(figsize=(10, 6))
sns.barplot(
    data=top_valore,
    x='Price',
    y='Product_Label',
    palette=sns.color_palette("Set2", n_colors=10)
)
plt.title("Top 10 Prodotti per Incasso Totale (€)")
plt.xlabel("Totale incassato (€)")
plt.ylabel("Prodotto")


for index, row in top_valore.iterrows():
    plt.text(row['Price'] + max(top_valore['Price'])*0.01, index,
             f"€{row['Price']:.2f}", va='center')

plt.tight_layout()
plt.show()
```

/tmp/ipykernel_702341/1315493899.py:8: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `y` variable to `hue` and set `legend=False` for the same effect.

```
sns.barplot(
```



```
[13]: # 7. Distribuzione del numero di prodotti per transazione

# Raggruppamento prodotti per ogni transazione
prod_per_trans = df.groupby('Transaction_ID')['Amount'].sum()

# Classi di quantità ordinate
bins = [0, 1, 2, 3, 5, 10, 20, 50, prod_per_trans.max()]
labels = ['1', '2', '3', '4-5', '6-10', '11-20', '21-50', '50+']
prod_per_trans_binned = pd.cut(prod_per_trans, bins=bins, labels=labels,
    right=True)

# Transazioni per fascia
distribuzione = prod_per_trans_binned.value_counts().sort_index()

# Grafico
plt.figure(figsize=(10, 6))
sns.barplot(x=distribuzione.index, y=distribuzione.values, palette="mako")
plt.title(" Quantità di Prodotti Ordinati per Transazione")
```



```

plt.xlabel("Quantità ordinata")
plt.ylabel("Numero di transazioni")

for i, val in enumerate(distribuzione.values):
    plt.text(i, val + max(distribuzione.values)*0.01, str(val), ha='center')

plt.tight_layout()
plt.show()

print(" Distribuzione quantità per transazione:\n")
print(distribuzione)

```


/tmp/ipykernel_689299/1201742756.py:16: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

```

sns.barplot(x=distribuzione.index, y=distribuzione.values, palette="mako")
/tmp/ipykernel_689299/1201742756.py:25: UserWarning: Glyph 128230 (\N{PACKAGE})
missing from font(s) DejaVu Sans.
plt.tight_layout()
/home/giovanni01/Scrivania/restaurant-data-challenge/.venv/lib/python3.12/site-
packages/IPython/core/pylabtools.py:170: UserWarning: Glyph 128230 (\N{PACKAGE})
missing from font(s) DejaVu Sans.
fig.canvas.print_figure(bytes_io, **kw)

```



Distribuzione quantità per transazione:

```
Amount
1      612
2      706
3     1070
4-5    6851
6-10   16981
11-20  15150
21-50   6776
50+     937
Name: count, dtype: int64
```

```
[10]: #8. Distribuzione vendite per giorno della settimana

df['Date'] = pd.to_datetime(df['Date'], dayfirst=True, errors='coerce')
df['Weekday'] = df['Date'].dt.day_name()

# Vendite per giorno della settimana
vendite_weekday = df.groupby('Weekday')['Price'].sum().reindex([
    'Monday', 'Tuesday', 'Wednesday', 'Thursday', 'Friday', 'Saturday', 'Sunday'
])

# Grafico
plt.figure(figsize=(10, 6))
sns.barplot(x=vendite_weekday.index, y=vendite_weekday.values, palette="rocket")
plt.title(" Vendite Totali per Giorno della Settimana")
plt.xlabel("Giorno")
plt.ylabel("Totale vendite (€)")

for i, val in enumerate(vendite_weekday.values):
    plt.text(i, val + max(vendite_weekday.values)*0.01, f"€{val:,.0f}",
             ha='center')

plt.tight_layout()
plt.show()

print(" Vendite totali per giorno della settimana:\n")
print(vendite_weekday.apply(lambda x: f"€{x:,.2f}"))
```

/tmp/ipykernel_702341/1718658086.py:13: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.


```
sns.barplot(x=vendite_weekday.index, y=vendite_weekday.values,
palette="rocket")
```

```
/tmp/ipykernel_702341/1718658086.py:21: UserWarning: Glyph 128198 (\N{TEAR-OFF CALENDAR}) missing from font(s) DejaVu Sans.
```

```
plt.tight_layout()
```

```
/home/giovanni01/Scrivania/restaurant-data-challenge/.venv/lib/python3.12/site-packages/IPython/core/pylabtools.py:170: UserWarning: Glyph 128198 (\N{TEAR-OFF CALENDAR}) missing from font(s) DejaVu Sans.
```

```
fig.canvas.print_figure(bytes_io, **kw)
```



Vendite totali per giorno della settimana:

Weekday

Monday €349,932.35

Tuesday €435,418.72

Wednesday €457,837.52

Thursday €462,256.24

Friday €502,244.15

Saturday €822,659.05

Sunday €580,192.88

Name: Price, dtype: object

```
[11]: #9 Clustering dei clienti
```

```
df['Date'] = pd.to_datetime(df['Date'])
```

```
# Dataset clienti aggregato
```

```
clienti = df.groupby('Transaction_ID').agg({
```

```

    'Price': 'sum',
    '#_guests': 'mean',
    'Amount': 'sum',
    'Lunch/Dinner': lambda x: (x == 'Cena').mean(),
    'At_the_table_Takeaway/Delivery': lambda x: (x == 'Asporto/Delivery').
    ↪mean(),
    'Product_category': pd.Series.nunique
}).reset_index()

clienti.columns = ['Transaction_ID', 'Totale_speso', 'Num_ospiti', ↪
    ↪'Totale_prodotti',
    ↪'Percentuale_cena', 'Percentuale_asporto', ↪
    ↪'Diversità_prodotti']

clienti.head()

```

```

[11]: Transaction_ID  Totale_speso  Num_ospiti  Totale_prodotti  Percentuale_cena \
0                1       155.00    1.187500           37.00         0.812500
1               10       122.00    0.000000           18.00         1.000000
2              100       116.00    2.600000           20.00         0.200000
3             1000       125.00    1.631579           21.00         0.368421
4            10000        55.95    1.000000           11.39         0.000000

    Percentuale_asporto  Diversità_prodotti
0                0.40625                10
1                1.00000                 5
2                0.00000                11
3                0.00000                12
4                0.00000                11

```

```

[12]: # Clustering con KMeans
from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans
from sklearn.decomposition import PCA

features = clienti.drop('Transaction_ID', axis=1)
scaler = StandardScaler()
scaled_features = scaler.fit_transform(features)

kmeans = KMeans(n_clusters=4, random_state=42)
clienti['Cluster'] = kmeans.fit_predict(scaled_features)

# Riduzione dimensionale per visualizzazione
pca = PCA(n_components=2)
pca_features = pca.fit_transform(scaled_features)
clienti['PCA1'] = pca_features[:,0]

```

```
clienti['PCA2'] = pca_features[:,1]
```


```
[13]: # Visualizzazione dei Cluster
plt.figure(figsize=(10, 6))
sns.scatterplot(data=clienti, x='PCA1', y='PCA2', hue='Cluster',
               palette='Set2', s=100)
plt.title(" Segmentazione Clienti (KMeans + PCA)")
plt.xlabel("PCA Component 1")
plt.ylabel("PCA Component 2")
plt.legend(title='Cluster')
plt.tight_layout()
plt.show()
```

/tmp/ipykernel_702341/2194858364.py:8: UserWarning: Glyph 127919 (\N{DIRECT HIT}) missing from font(s) DejaVu Sans.

```
plt.tight_layout()
```

/home/giovanni01/Scrivania/restaurant-data-challenge/.venv/lib/python3.12/site-packages/IPython/core/pylabtools.py:170: UserWarning: Glyph 127919 (\N{DIRECT HIT}) missing from font(s) DejaVu Sans.

```
fig.canvas.print_figure(bytes_io, **kw)
```



```
[14]: # Medie per cluster
profilo_cluster = clienti.groupby('Cluster')[clienti.
      select_dtypes(include='number').columns].mean().round(2)
print(" Profili cluster:\n")
print(profilo_cluster)
```

Profili cluster:

	Totale_speso	Num_ospiti	Totale_prodotti	Percentuale_cena \
Cluster				
0	260.12	6.03	43.54	0.72
1	56.36	1.95	10.65	0.00
2	35.67	0.00	7.27	0.63
3	67.73	2.30	12.51	0.99

	Percentuale_asporto	Diversità_prodotti	Cluster	PCA1	PCA2
Cluster					
0	0.04	11.78	0.0	4.12	0.59
1	0.00	6.68	1.0	-0.20	-1.21
2	1.00	4.34	2.0	-1.85	1.29
3	0.01	7.31	3.0	0.26	0.27

2 Conclusioni e Insight

2.1 Andamento Vendite

- Le **vendite giornaliere** mostrano flussi costanti con picchi marcati durante i weekend.
- Il **sabato** è il giorno con il maggiore incasso totale, seguito dalla **domenica**, a conferma della centralità dei servizi del fine settimana.

2.2 Lunch vs Dinner

- La fascia **serale (Dinner)** rappresenta la quota maggiore di vendite totali.
- Alcuni cluster di clienti sono fortemente associati alla cena, con una spesa media più alta rispetto al pranzo.

2.3 Prodotti e Categorie

- I **prodotti più venduti** sono in prevalenza della categoria **PIZZE**.
- I **prodotti con il maggiore incasso complessivo** appartengono anch'essi a PIZZE, seguiti da BEVERAGE.
- Analisi di categoria ha evidenziato una **forte concentrazione delle vendite** in pochi prodotti top.

2.4 Scontrino Medio

- Lo **scontrino medio per transazione** è di circa **€ 73,56**
- Transazioni con più ospiti generano uno scontrino maggiore, ma meno frequente.

2.5 Tipologia Consumo

- La maggior parte delle vendite avviene **al tavolo**.
- Tuttavia, un segmento rilevante (Cluster 2) è composto **esclusivamente da clienti take-away/delivery**, con comportamento distinto e mirato.

2.6 Segmentazione Clienti (KMeans)

Attraverso l'analisi dei pattern d'acquisto è stata effettuata una **segmentazione della clientela** tramite KMeans (supportata da PCA):

Cluster	Totale Speso (€)	N. Ospiti	Totale Prodotti	% Cena	% Asporto	Diversità Prodotti
0	260.12	6.03	43.54	0.72	0.04	11.78
1	56.36	1.95	10.65	0.00	0.00	6.68
2	35.67	0.00	7.27	0.63	1.00	4.34
3	67.73	2.30	12.51	0.99	0.01	7.31

- **Cluster 0:** Clienti ad alta spesa e alta varietà, spesso in gruppo, tipicamente a cena.
- **Cluster 1:** Clienti con basso consumo, visita occasionale.
- **Cluster 2:** Completamente orientati all'asporto, bassa spesa e varietà.
- **Cluster 3:** Frequentano la cena con regolarità, spesa medio-bassa ma stabile.

2.7 Conclusione

L'analisi ha permesso di:

- Identificare pattern ricorrenti di consumo e orari
- Evidenziare i prodotti core su cui concentrare l'offerta
- Segmentare la clientela per strategie mirate